

Aula 0 — Introdução ao Curso

Arquiteturas Cloud-Native e Formatos Modernos de Dados para Oceanografia Operacional,
Clima e Meteorologia em Escala de Múltiplos Terabytes (Arq-Cloud)

Tobias Ferreira

Instituto Nacional de Pesquisas Oceânicas (INPO)

01/09/2026

Por que este curso?

A oceanografia, a meteorologia e a climatologia trabalham cada vez mais com dados grandes, distribuídos e difíceis de mover.

Neste curso, vamos discutir como organizar, processar, acessar e visualizar esses dados de forma mais eficiente.

Ideia central

Não basta saber abrir um arquivo: precisamos entender como o dado é armazenado, acessado, processado e compartilhado.

Objetivo do workshop

Este workshop apresenta ferramentas e fluxos práticos para trabalhar com grandes conjuntos de dados científicos N-dimensionais de forma mais compatível com ambientes de nuvem.

- dados de oceanografia;
- dados de clima;
- dados de meteorologia;
- dados ambientais em múltiplas dimensões.

O que você vai aprender

- Migrar dados ambientais de formatos tradicionais, como NetCDF, para formatos cloud-native, como Zarr e VirtualiZarr.
- Armazenar, processar e acessar datasets de múltiplos terabytes usando object storage e processamento paralelo.
- Usar ferramentas como Dask para dividir o trabalho em tarefas menores.
- Construir fluxos escaláveis e reproduzíveis para análise de dados ambientais.
- Visualizar e explorar grandes datasets diretamente a partir da nuvem.

Mensagem importante

O foco não é apenas aprender comandos, mas entender por que essas ferramentas são úteis.

Atividade inicial: que dados você usa?

Antes de começarmos, vamos entender melhor a experiência do grupo.

No documento compartilhado **CodiMD**, escreva:

- 1 uma frase sobre os dados com que você costuma trabalhar e o tamanho aproximado deles;
- 2 um desafio que você já enfrentou com dados grandes demais ou lentos demais para processar;
- 3 uma ferramenta, biblioteca ou sistema computacional que você já usou para análise, armazenamento ou acesso a dados.

Objetivo

Conectar os conceitos do curso com problemas reais trazidos pelos participantes.

Ambiente do curso

Durante o workshop, vamos usar um ambiente Python com as principais bibliotecas necessárias.

- jupyterlab
- numpy
- netCDF4
- xarray
- zarr
- dask
- fsspec, s3fs, boto3, obstore
- matplotlib e cartopy
- icechunk
- virtualizarr
- stac
- topozarr

Reprodutibilidade

O ambiente completo é definido no arquivo `environment.yml` do repositório do curso.

Mapa das ferramentas

Grupo	Ferramentas	Papel no curso
Análise	xarray, numpy	Dados N-dimensionais
Processamento	dask	Paralelismo e escala
Formatos	netCDF4, zarr	Leitura, escrita e conversão
Acesso remoto	fsspec, s3fs, boto3	Object storage
Versionamento	icechunk	Histórico de dados Zarr
Catálogo	STAC	Organização e descoberta
Visualização	matplotlib, cartopy	Mapas e gráficos

Antes de avançarmos, vamos alinhar alguns termos que aparecerão ao longo do curso.

Por que isso importa?

Muitos problemas com dados grandes aparecem porque usamos as mesmas palavras para coisas diferentes: memória, armazenamento, processo, thread, cluster, nuvem, bucket, formato, metadados.

CPU, core, processo e thread

- **CPU:** unidade que executa instruções e cálculos.
- **Core:** uma unidade de processamento dentro da CPU.
- **Processo:** uma instância de um programa em execução.
- **Thread:** unidade menor de trabalho dentro de um processo.



Processamento paralelo significa dividir uma tarefa em partes menores que podem ser executadas ao mesmo tempo.

Dask

Dask é uma biblioteca Python que organiza grandes computações em tarefas menores, que podem ser executadas em paralelo em cores, processos ou workers.

A ideia é trabalhar com dados maiores sem depender de uma única operação gigante.

RAM

Memória de curto prazo do computador. É rápida, mas limitada.

- usada durante cálculos;
- pode limitar análises grandes;
- desaparece quando o processo termina.

Armazenamento

Onde os dados vivem de forma mais permanente.


- disco local ou SSD;
- storage compartilhado;
- object storage;
- sistemas de arquivos em HPC.

Cluster, node e HPC

- **Cluster:** conjunto de computadores conectados.
- **Node:** um computador dentro do cluster.
- **HPC:** sistema compartilhado para computação pesada e processamento de grandes volumes de dados.

Exemplo

O JASMIN é uma infraestrutura usada para ciência ambiental intensiva em dados.




Fonte: JASMIN.

JASMIN é a infraestrutura do Reino Unido para análise de dados ambientais intensivos.

Ela oferece:

- notebooks;
- armazenamento compartilhado;
- recursos computacionais;
- ambientes para dados grandes.

SSH é uma forma segura de conectar a computadores remotos.



Um **group workspace** é uma área de armazenamento compartilhada no JASMIN.

- permite colaboração entre usuários;
- evita múltiplas cópias locais dos mesmos dados;
- facilita o acesso aos dados do curso;
- aproxima o processamento do local onde os dados estão armazenados.

Jupyter notebook

Ambiente no navegador para combinar código, texto, resultados, tabelas e gráficos.

- útil para exploração;
- facilita demonstrações;
- permite documentação junto com o código.

Kernel

Ambiente Python que executa o código do notebook.

- define quais pacotes estão disponíveis;
- mantém variáveis em memória;
- pode ser reiniciado durante o trabalho.

environment.yml, conda e mamba

environment.yml descreve a versão do Python e os pacotes necessários para reproduzir o ambiente.

```
conda env create -f environment.yml  
conda activate cloud-native-geoscience-course
```

- **conda**: gerencia ambientes e pacotes.
- **mamba**: alternativa mais rápida para resolver e instalar pacotes.

Dataset, array, coordenada e variável

- **Dataset:** conjunto de dados e metadados relacionados.
- **Array:** grade multidimensional de valores.
- **Coordenada:** eixo nomeado, como tempo, latitude, longitude ou profundidade.
- **Variável:** valor medido ou modelado, como temperatura ou salinidade.

$$T = T(x, y, z, t)$$

Exemplo

Temperatura do oceano variando no espaço, na profundidade e no tempo.

Metadados são informações que explicam o que os dados significam.

- unidades;
- nomes longos;
- coordenadas;
- dimensões;
- projeções;
- convenções e atributos.

Vocabulário controlado

Lista padronizada de termos e identificadores para reduzir ambiguidade.

Zarr, Xarray, chunk e lazy loading

- **Zarr**: formato chunked para arrays N-dimensionais grandes.
- **Xarray**: biblioteca Python para trabalhar com arrays rotulados e metadados.
- **Chunk**: pedaço menor de um array grande.
- **Lazy loading**: os dados não são lidos completamente ao abrir o dataset; são carregados apenas quando necessário.


Ideia prática

Abrir um dataset grande não significa colocar todo o dataset na memória.

Object storage e bucket

Object storage guarda dados como objetos independentes, geralmente acessados por APIs como S3.

- **Bucket:** contêiner principal para objetos.
- **Object:** unidade armazenada, com dados e metadados.
- Muito usado em nuvem e em fluxos cloud-native.



Sistema POSIX

- arquivos e diretórios;
- caminhos tradicionais;
- disco local ou filesystem compartilhado;
- muito comum em HPC.

Object store

- objetos acessados por API;
- buckets e chaves;
- bom para acesso remoto e paralelo;
- não se comporta exatamente como um disco tradicional.

Consequência

Nem todo fluxo pensado para arquivos locais funciona bem em object storage.


Um formato **cloud-native** é desenhado para funcionar bem com acesso remoto e object storage.

Normalmente ele permite:

- leitura parcial dos dados;
- acesso paralelo;
- redução de downloads completos;
- melhor integração com processamento distribuído;
- compartilhamento mais eficiente.

STAC é um padrão para descrever e organizar assets geoespaciais.

- facilita descoberta de dados;
- organiza coleções, itens e assets;
- conecta metadados com arquivos e serviços;
- é muito usado em catálogos cloud-native.



Fonte: STAC.

Icechunk

Adiciona versionamento, histórico e controle de mudanças a stores Zarr.

- branches;
- tags;
- reprodutibilidade;
- rastreamento de alterações.

VirtualiZarr

Permite trabalhar com arquivos existentes como se fossem datasets Zarr, sem copiar todos os dados.

- útil para migração gradual;
- reduz cópias;
- cria uma camada virtual de acesso.

Um dataset **multiscale** armazena a mesma informação em múltiplas resoluções.

Uma **pirâmide** é a estrutura em camadas que permite visualizar rapidamente uma versão mais grosseira e depois aproximar para níveis mais detalhados.

Por que isso importa?

É uma estratégia essencial para visualização eficiente de grandes datasets na web.

Como esses conceitos aparecem no curso

- Começamos com os desafios de dados N-dimensionais e formatos tradicionais.
- Depois discutimos object storage, acesso parcial e formatos cloud-native.
- Em seguida, usamos Zarr, Dask e ferramentas de conversão.
- Também veremos catálogos STAC, versionamento com Icechunk e visualização web.

Fio condutor

Mover menos dados, processar de forma mais inteligente e tornar o fluxo mais reproduzível.

- O curso apresenta fluxos cloud-native para dados ambientais grandes.
- O foco está em oceanografia, clima e meteorologia.
- Vamos trabalhar com formatos, processamento paralelo, object storage, catálogos e visualização.
- Conceitos como CPU, RAM, cluster, chunk, lazy loading e metadados serão usados durante todo o curso.
- A atividade inicial ajuda a conectar o conteúdo aos desafios reais dos participantes.