

Aula 1 — Formatos de Dados, Metadados e Vocabulários

Arquiteturas Cloud-Native e Formatos Modernos de Dados para Oceanografia Operacional,
Clima e Meteorologia em Escala de Múltiplos Terabytes (Arq-Cloud)

Tobias Ferreira

Instituto Nacional de Pesquisas Oceânicas (INPO)

01/09/2026

Onde esta aula se encaixa?

Antes de falar sobre cloud-native, Zarr, Dask e object storage, precisamos responder uma pergunta mais básica:

Pergunta central

Como representamos dados ambientais de forma que humanos e máquinas consigam entender, encontrar, reutilizar e processar esses dados corretamente?

Formato sem metadados vira apenas bytes. Metadados sem padrão viram ambiguidade.

Objetivos da aula

Ao final desta aula, você deverá conseguir:

- reconhecer formatos comuns em oceanografia e meteorologia, como NetCDF, GRIB, BUFR e Zarr;
- explicar o que são metadados e por que eles são essenciais para descoberta e reuso;
- descrever o papel dos vocabulários controlados na padronização de termos;
- identificar padrões importantes, como CF, ISO 19115, INSPIRE, MEDIN e NERC NVS;
- relacionar formatos tradicionais com formatos cloud-native, como Zarr.

Perguntas que vamos responder

- Quais formatos são usados para armazenar dados de oceano e atmosfera?
- O que é metadado e como ele ajuda outras pessoas a entenderem meus dados?
- Por que vocabulário controlado é melhor do que texto livre?
- Quais padrões devo conhecer ao publicar dados ambientais?
- Como tudo isso se conecta a formatos modernos como Zarr?

Por que formatos e metadados importam?

Quando trabalhamos com dados ambientais, não armazenamos apenas números.

Também precisamos codificar o **significado**:

- o que foi medido;
- onde e quando foi medido;
- como foi medido ou processado;
- quais unidades, coordenadas e métodos foram usados;
- como o dado deve ser interpretado e reutilizado.

Dois níveis do problema

Formato

Define como dados e metadados são organizados fisicamente.

- arrays ou tabelas;
- grades ou vetores;
- binário ou texto;
- arquivo único ou coleção;
- legado ou cloud-native.

Semântica

Define o significado dos dados.

- nomes de variáveis;
- unidades;
- coordenadas;
- sistema de referência;
- qualidade e proveniência;
- termos controlados.

Famílias de formatos ambientais

- formatos de arrays auto-descritivos;
- formatos operacionais da WMO;
- formatos raster e vetoriais para GIS;
- formatos tabulares e colunares;
- formatos JSON/XML para catálogos e APIs.

Foco do curso

Dados multidimensionais de oceano, clima e meteorologia.



Formatos auto-descritivos de arrays

Formato	Uso comum	Ideia principal
NetCDF	Clima, oceano, reanálise	Arrays + dimensões + atributos
HDF5	Satélite, modelos, ciência	Estrutura hierárquica de grupos
Zarr	Dados grandes e cloud-native	Arrays em chunks e acesso paralelo

Por que isso importa?

Esses formatos carregam dados e metadados estruturais no mesmo dataset: dimensões, variáveis, unidades, coordenadas e atributos.

- Formato binário, independente de máquina, muito usado para dados científicos orientados a arrays.
- Amplamente adotado em oceanografia, clima e meteorologia.
- Armazena variáveis, dimensões, coordenadas e atributos.
- Frequentemente usado com convenções CF para tornar os metadados interpretáveis por ferramentas científicas.

Exemplo

`sea_surface_temperature.nc` contendo latitude, longitude, tempo, temperatura da superfície do mar, unidades e outros metadados.

- Formato auto-descritivo para datasets grandes e complexos.
- Organiza dados em uma estrutura hierárquica, parecida com diretórios.
- Usa grupos, datasets e atributos.
- Muito comum em produtos de satélite, observações complexas e saídas de modelos.

Exemplo

`satellite_observations.h5` com grupos separados para geolocalização, medições, flags de qualidade e metadados.

- Formato para arrays N-dimensionais divididos em **chunks**.
- Funciona bem com object storage e acesso remoto.
- Permite leitura parcial e processamento paralelo.
- Pode representar dados geoespaciais usando convenções como GeoZarr e conceitos do modelo comum de dados da Unidata.

Exemplo

`ocean_model.zarr` com temperatura, salinidade e velocidade indexadas por tempo, profundidade, latitude e longitude.

GRIB

Formato binário compacto para campos meteorológicos em grade, muito usado em previsão numérica do tempo.

- eficiente para disseminação operacional;
- baseado em mensagens;
- metadados codificados em tabelas.

BUFR

Formato binário flexível e orientado por tabelas para observações meteorológicas e oceanográficas.

- usado para satélites, aeronaves e perfis;
- representa muitos tipos de observação;
- pode carregar informação de qualidade.

Outros formatos que aparecem no fluxo

Formato	Tipo	Uso típico
CSV / ASCII	Tabela simples	Dados pequenos, inspeção manual
GeoTIFF / COG	Raster 2D	Mapas, sensoriamento remoto
GeoJSON	Vetor JSON	Footprints, regiões, APIs
Shapefile	Vetor GIS	Pontos, linhas e polígonos
Parquet / GeoParquet	Colunar	Analytics e grandes tabelas
XML / JSON	Documento	Metadados, catálogos e APIs

Mensagem

Nem todo formato serve ao mesmo propósito. Muitos deles orbitam o dataset principal, oferecendo contexto, catálogo ou acesso.

Conceito: dado auto-descritivo

Um arquivo é **auto-descritivo** quando contém metadados estruturais suficientes para que uma ferramenta consiga interpretar e subconjuntar os dados sem depender de documentação externa.

- dimensões;
- variáveis;
- unidades;
- coordenadas;
- atributos;
- sistemas de referência.

Parquet e GeoParquet na prática

- Parquet é um formato colunar, comprimido e eficiente para grandes tabelas.
- GeoParquet adiciona convenções para armazenar geometrias vetoriais junto com atributos tabulares.
- São comuns em data lakes, lakehouses, analytics e plataformas GIS modernas.
- Podem substituir fluxos baseados em CSV, Shapefile e GeoJSON em dados vetoriais grandes.

Neste curso

Eles fazem parte do ecossistema cloud-native, mas nosso foco principal são arrays auto-descritivos: NetCDF e Zarr.

O que é metadado?

Metadado é “dado sobre o dado”: informação que descreve um dataset para que pessoas e softwares consigam entender, encontrar e reutilizar esse dataset.

Em dados marinhos e atmosféricos, metadados respondem:

- quem coletou o dado e por quê;
- o que foi medido e em quais unidades;
- onde e quando foi medido;
- como foi processado;
- como acessar, citar e interpretar o dado.

Elementos comuns de metadados

- título e resumo;
- variáveis e unidades;
- extensão espacial;
- extensão temporal;
- sistema de coordenadas;
- flags de qualidade;
- proveniência e versão;
- links de acesso e citação.



Texto livre pode ser ambíguo:

temp T temperature sea temperature

Vocabulários controlados resolvem isso usando listas curadas de termos padronizados e identificadores estáveis.

Benefício

Diferentes datasets e instituições passam a usar o mesmo conceito quando querem dizer a mesma coisa.

- Serviço operado pelo British Oceanographic Data Centre (BODC).
- Publica vocabulários para dados marinhos e de ciências da Terra.
- Inclui termos para parâmetros, instrumentos, plataformas, projetos, regiões e métodos.
- Usa identificadores estáveis, permitindo metadados legíveis por máquina.

Exemplo

Uma variável como “temperatura da água do mar a 5 m” pode ser associada a um código P01, reduzindo ambiguidade entre datasets.

Padrões importantes

Padrão	Escopo	Papel
CF Conventions	Dentro do arquivo	Variáveis, unidades, coordenadas
ISO 19115	Dataset como um todo	Descoberta e documentação geográfica
INSPIRE	Perfil europeu	Regras para metadados espaciais
MEDIN	Perfil marinho do Reino Unido	Descoberta de dados marinhos
NVS	Vocabulários	Termos e identificadores estáveis
STAC	Catálogo JSON/GeoJSON	Organização de assets no espaço e tempo

As convenções CF definem como descrever dados de ciências da Terra em formatos auto-descritivos, originalmente NetCDF.

CF especifica atributos como:

- `standard_name`;
- `units`;
- `cell_methods`;
- `coordinates`;
- `bounds`;
- `grid_mapping`.

Exemplo CF em NetCDF

```
sea_surface_temperature:  
  standard_name = "sea_surface_temperature"  
  units = "K"  
  coordinates = "time latitude longitude"
```

Por que isso ajuda?

Ferramentas como xarray conseguem entender melhor o que a variável representa e como ela se relaciona com as coordenadas do dataset.

- ISO 19115 descreve datasets e serviços geográficos.
- Inclui identificação, extensão espacial e temporal, qualidade, sistema de referência, responsáveis e distribuição.
- INSPIRE define regras de metadados para dados e serviços espaciais no contexto europeu.
- Perfis comunitários, como MEDIN e SeaDataNet, adaptam esses padrões a comunidades específicas.

Diferença importante

CF descreve variáveis dentro do arquivo; ISO e perfis de descoberta descrevem o dataset como um todo.

Exemplo de metadado de descoberta

Title: CTD observations from the North Atlantic, 2025
Organisation: National Oceanography Centre
Geographic extent: 45N-60N, 30W-10W
Temporal extent: 10-25 June 2025
Keywords: ocean temperature, salinity, CTD
Coordinate reference system: WGS 84
Distribution format: NetCDF

- A WMO mantém formatos para troca eficiente de dados meteorológicos e oceanográficos.
- GRIB é amplamente usado para saídas de previsão numérica do tempo.
- BUFR é usado para grandes volumes de observações, como satélites, aeronaves e perfiladores.
- Esses formatos são essenciais em centros operacionais.

Conexão com cloud-native

Mesmo quando os dados operacionais chegam em GRIB ou BUFR, eles podem ser convertidos, catalogados e expostos em fluxos modernos.

STAC define uma linguagem comum, baseada em JSON/GeoJSON, para descrever e organizar assets geoespaciais no espaço e no tempo.

- **Catalog**: ponto de entrada que conecta coleções e itens.
- **Collection**: conjunto relacionado de dados com metadados compartilhados.
- **Item**: um asset ou produto específico, com links para os arquivos de dados.

Metadado dentro do arquivo vs metadado de descoberta

Dentro do arquivo

Usado por ferramentas de análise.

- units;
- standard_name;
- long_name;
- coordenadas;
- histórico e proveniência.

Descoberta

Usado por catálogos e usuários.

- título e resumo;
- palavras-chave;
- contato;
- extensão espacial e temporal;
- links de acesso;
- licença e citação.

Por que os dois são necessários?

Metadados internos

Permitem que ferramentas como xarray, Iris, CDO e bibliotecas de visualização interpretem arrays corretamente.

Metadados de descoberta

Permitem que pessoas, catálogos e APIs encontrem o dataset e decidam se ele serve para uma análise.

Um dataset reutilizável precisa dos dois níveis.

Exercício 1: combine formato e padrão

Para cada cenário, sugira uma combinação de **formato** + **padrão de metadados** e explique o motivo.

- 1 Reanálise global diária de temperatura da superfície do mar em grade regular, publicada para reuso de longo prazo.
- 2 Perfis CTD de navio, com metadados detalhados de instrumento, para ingestão em um centro nacional de dados marinhos.
- 3 Campos operacionais globais de previsão numérica do tempo disseminados a cada 6 horas.

Tempo

5 minutos para pensar ou discutir em pares. Depois compartilhamos as respostas.

Possíveis respostas para o exercício 1

- ❶ **SST em grade:** NetCDF ou Zarr com convenções CF, metadados de descoberta ISO/INSPIRE/MEDIN e, opcionalmente, STAC para expor os assets em um catálogo cloud-native.
- ❷ **Perfis CTD:** NetCDF ou CSV com metadados internos ricos, MEDIN para descoberta, e NVS para parâmetros, instrumentos e plataformas.
- ❸ **Previsão operacional:** GRIB/GRIB2 com metadados WMO, além de catálogo ou API baseado em ISO/INSPIRE, perfil institucional ou STAC para descoberta.

Ideia principal

A melhor escolha depende do tipo de dado, do público, do fluxo operacional e da forma de acesso.

Por que seguir padrões?

- **Interoperabilidade:** ferramentas conseguem ler e interpretar dados sem código customizado.
- **Descoberta:** catálogos conseguem indexar e divulgar datasets.
- **Clareza semântica:** vocabulários reduzem ambiguidade entre instituições.
- **Governança:** padrões ajudam auditoria, documentação, qualidade e manutenção.
- **Eficiência:** reutilizamos ferramentas e infraestruturas existentes em vez de reinventar tudo.

Formatos cloud-native não eliminam a necessidade de padrões.

Pelo contrário

Quando movemos dados de arquivos locais para object storage, APIs e catálogos, os padrões são o que preservam o significado dos dados.

Zarr, GeoZarr, CF, NVS, ISO e STAC podem trabalhar juntos para conectar o ecossistema científico ao ecossistema geoespacial moderno.

Exercício 2: encontre o metadado ausente

Imagine que você encontra um arquivo `sst_daily.nc` com uma variável global de temperatura da superfície do mar.

Dentro do arquivo você vê:

- nome da variável: `temp`;
- sem atributo `units`;
- sem atributo `standard_name`;
- coordenada de tempo sem `calendar` ou referência como “days since ...”.

Que problemas isso pode causar? O que você adicionaria?

Possíveis respostas para o exercício 2

- Sem `units`, não sabemos se `temp` está em Kelvin, Celsius ou outra unidade.
- Sem `standard_name`, ferramentas não reconhecem automaticamente a variável como temperatura da superfície do mar.
- Sem metadados de tempo, fica difícil alinhar o dado com outros datasets.

Melhorias mínimas

Adicionar `standard_name="sea_surface_temperature"`, `units="K"`, `long_name`, metadados corretos de tempo, título, instituição, resumo, palavras-chave e extensão espacial/temporal.

- Oceanografia e meteorologia dependem de formatos auto-descritivos, como NetCDF, HDF5 e Zarr, e de formatos operacionais, como GRIB e BUFR.
- Metadados existem tanto dentro dos arquivos quanto em registros externos de descoberta.
- Vocabulários controlados, como NVS, tornam metadados mais consistentes e legíveis por máquina.
- CF descreve variáveis, grades e coordenadas em formatos científicos.
- ISO, INSPIRE e MEDIN ajudam na descoberta e documentação de datasets.
- STAC organiza assets geoespaciais em fluxos modernos e cloud-native.

Nesta aula, vimos que formatos, metadados e vocabulários não são detalhes administrativos.

Eles são a base para escala

Sem padrões, fica difícil automatizar análise, busca, visualização, conversão e acesso remoto.

Na próxima etapa, conectamos essa base ao problema central do curso: trabalhar com dados N-dimensionais grandes em ambientes modernos de processamento e armazenamento.